统计口径 / 一页详解

示意图：宽度不代表实测耗时

整轮HC周期如何拆解：层区间、层间衔接与15阶段

源8主层＋3草稿层 → 目标61主层＋3草稿层 ｜ 设备锚点连续跨度 · 实测分区与外推假设分开

01 整轮时间轴：从主0首HCPre.start，到下一轮主0首HCPre.start

主模型层链：8个层区间 ＋ 7段层间衔接

主0 | 主1 | 主2 | 主3 | 主4 | 主5 | 主6 | 主7 → U1：主 → 草稿（8个父阶段）→ 草0 | 草1 | 草2 → U2：草稿 → 下一轮主（7个父阶段）→ 下一轮起点

草稿层链：3个层区间 ＋ 2段衔接

① 主层区间 + ② 主衔接（黄色小段）

U1：主末HCPost → 草首HCPre

③ 草稿层区间 + ④ 草稿衔接

U2：草末HCPost → 下轮主首HCPre

R源 / R目标均按五项闭合：①主层区间 ＋ ②主衔接 ＋ ③草稿层区间 ＋ ④草稿衔接 ＋ ⑤U（U1＋U2）

02 放大一层：首个clone在HC统计起点之前，另计

源码层内的前置工作

本层 W：首HCPre.start → 末HCPost.end

首个clone 残差保存 → 首HCPre Attention入口 → Norm → Attention → HCPost → clone → HCPre → Norm → MoE（Dispatch / Combine） → 末HCPost FFN出口

计入此前衔接 / U末段

W内已包含Attention、FFN主体，以及中间的clone；不等于完整Python层耗时

Gi = 下一层首HCPre.start − 本层末HCPost.end；该段可含clone、辅助特征处理及任务间隔。

03 8主 → 61主：层均值重建，衔接另算

主层：31×HCA目标均值 ＋ 30×CSA目标均值

HCA参考主1/3/5/7；CSA参考主2/4/6；主0仅排除参考，目标仍为61层

主衔接：源7段之和 ＋ 53×源6段参考均值

0→1保留在源7段中；新增53段的6段参考均值不含0→1

草稿：3×SWA目标均值 ＋ 源2段衔接；U保留一次

目标均值＝源类别均值＋Δ通信＋Δ路由GMM；新增衔接及U沿用属于估算假设

04 只展开第⑤项 U：8 ＋ 7 ＝ 15个父阶段，不能重复加到整轮

连续跨度含段内间隔；子阶段已包含于父阶段

U1 主模型末HCPost.end → 草稿首HCPre.start

01 主输出归并与HC Head	02 最终Norm与词表投影	03 拒绝采样与状态更新	04 草稿上下文特征融合	05 DFlash输入准备	06 Context KV投影与写入	07 草稿metadata与输入映射	08 草稿Embedding与HC展开
收拢末主输出	含采样前整理	决定接受结果	辅助特征拼接 / 投影	按KV组准备	供草稿读取上下文	准备注意力元信息	含首HCPre前准备

U2 草稿末HCPost.end → 下一轮主0首HCPre.start

09 草稿输出归并与HC Head	10 草稿最终Norm与词表投影	11 逐位置Markov偏置与选token	12 草稿结果整理与轮次交接	13 下一主模型KV与输入准备	14 下一主metadata与输入映射	15 下一主Embedding与HC展开
收拢草稿输出	得到草稿logits	S=7时含7个子位置	整理候选与状态	合并token / 位置 / slots	准备注意力元信息	含首HCPre前准备

第8、15段覆盖到首HCPre之前：可含HC展开后的clone等准备；clone为源码逻辑，不保证在CSV中独立成项。

口径：HC区间≠完整Python层；衔接和U可含实际任务与间隔，不直接称“空闲”。15段为当前已核对路径；缺锚点保留未识别整窗。

汇总：逐rank逐轮估算 → 各rank周期均值 → 取最大rank；全部分项用同一rank。方法1每次D/C目标调用加14μs；方法2不叠加。

依据：profile_ep128.py（20261103.12.native_stages） · a_hc_cycles / _lm_source_round / _lm_estimate_method / residual_stage_plan；宽度不表示耗时比例。